Avance del proyecto

Guía de trabajo para el equipo. El sistema recibe una foto de una pieza sobre fondo uniforme y estima su calidad y su tamaño relativo.

33.728
imágenes en el inventario

17.481
grupos para la partición

42
fotos propias registradas

Trabajo completado

- **Revisión de las fuentes.** Kaggle aporta 19.526 archivos, AgriFreshNET 14.160 y el equipo 42. El inventario se genera con `python -m src.data.inventory`.
- **Criterios acordados. good** para piezas completas con color habitual, **regular** para deterioro inicial y **bad** para hongos, decoloración marcada o podredumbre visible. *Semi-Fresh* pasa a **regular**.
- **Identificación y grupos.** Nueve fotos propias tienen ID asignado. Las tomas dudosas se agruparon por sesión y producto. Las variantes y copias externas comparten grupo.
- **EDA reproducible.** El notebook contiene conteos por producto, fuente y calidad, y seis fotos de banano que ilustran las tres clases.

Desbalance de calidad

Clase	Archivos etiquetados	Grupos por clase	% de grupos
good	16.364	8.265	49,8 %
regular	4.705	1.642	9,9 %
bad	11.510	6.678	40,3 %

El análisis de clase usa 32.579 archivos en 16.581 grupos con etiqueta disponible. Un grupo puede figurar en varias clases.

- **Regular depende de una fuente.** AgriFreshNET aporta 4.695 de los 4.705 archivos regulares. Manzana, guayaba, lima y granada carecen de ejemplos regulares etiquetados.
- **Tamaño con poca variedad.** Hay 33 imágenes etiquetadas como medianas y dos como pequeñas. Faltan ejemplos grandes para evaluar esa categoría.

Repositorio del equipo

Tareas pendientes

Primero cerrar la preparación de datos. Después entrenar, evaluar y preparar la sustentación.

01 **Revisar anotaciones pendientes**

Resolver 17 grupos con etiquetas en conflicto en AgriFreshNET. Anotar calidad y tamaño de los seis mangos y confirmar los IDs dudosos de las fotos propias.

02 **Segmentar y preparar las imágenes**

Revisar fotos con varias piezas. Para aprovechar Mixed, separar las piezas con OpenCV y etiquetar cada recorte como good, regular o bad. Hay 1.074 escenas de Mixed y un racimo propio pendientes. Guardar recortes redimensionados y medir el diámetro normalizado.

03 **Crear las particiones**

Separar entrenamiento, validación y prueba por grupo, con estratificación por calidad cuando sea viable. Mantener juntas las tomas de la misma pieza y sus variantes. Revisar la cobertura de fuentes y productos en cada partición.

04 **Entrenar los modelos**

Usar regresión logística sobre histogramas de color como línea base. Ajustar SVM y Random Forest con validación cruzada por grupos. Entrenar una CNN pequeña desde cero y aplicar aumento de datos sobre entrenamiento.

05 **Evaluar calidad y tamaño**

Comparar F1 macro, matrices de confusión y errores por clase, producto y fuente. Validar el diámetro normalizado o los rangos de tamaño con ejemplos anotados.

06 **Preparar la app de Streamlit**

Aceptar carga de imágenes y captura por cámara. Mostrar la clase de calidad y el tamaño relativo de una pieza.

07 **Cerrar la entrega del curso**

Documentar las fases y el diagrama de CRISP-DM, las decisiones éticas, los impactos y la justificación matemática. Preparar el informe de hasta siete páginas, el video de hasta diez minutos y revisar la rúbrica en INTU.

Fuentes de la guía: inventario local y notebook de EDA, consigna «Proyecto Final 26-2» y documento de competencias del curso.